Wir schauen erneut auf Aufgabe 3 von Übungsblatt 2. Die Rohdaten dort waren:

	Pizzatyp				
	Margherita	Salami	Hawaii	Tonno	Funghi
Deutschland	42	20	16	18	14
Italien	30	25	0	22	23
Frankreich	35	40	12	10	33

Die erwarteten Häufigkeiten v_{jk} wurden berechnet als:

erwartete Häufigkeiten	Pizzatyp					
	Margherita	Salami	Hawaii	Tonno	Funghi	Σ
Deutschland	$\frac{110 \cdot 107}{340} = 34.62$	27.5	9.06	16.18	22.65	110
Italien	31.47	25.0	8.24	14.71	20.59	100
Frankreich	40.91	32.5	10.71	19.12	26.76	130
Σ	107	85	28	50	70	340

a) (2 Punkte) Berechnen Sie den χ^2-Kontingenzkoeffizienten.

$$\chi^2 = \sum_{j=1}^{J} \sum_{k=1}^{K} \frac{(N_{jk} - v_{jk})^2}{v_{jk}} = \frac{(42-34{,}62)^2}{34{,}62} + \frac{(20-27{,}5)^2}{27{,}5} + \dots$$

$$= 33{,}19 \quad \text{(Excel)}$$

jeder Term:				
1.57	2.05	5.32	0.21	3.30
0.07	0.00	8.24	3.62	0.28
0.85	1.73	0.16	4.35	1.45

b) (2 Punkte) Berechnen Sie den korrigierten Kontingenzkoeffizienten nach Pearson. Interpretieren Sie das Ergebnis.

$$\min\{J, K\} = 3$$

$$C = \sqrt{\frac{\chi^2}{\chi^2 + N} \cdot \frac{3}{3-1}} = \sqrt{\frac{33{,}19}{33{,}19 + 340} \cdot \frac{3}{2}} = 0{,}365$$

$\rightarrow$ mittlere schwache Abhängigkeit

Aufgabe 2 **(8 Punkte)**

Die Hobbystatistikerin B. Rechnen übt ihre Statistikkenntnisse gerne an selbsterhobenen Datensätzen. Erst gestern hat sie die Körpergrößen und Alter der Kinder in der Nachbarschaft erhoben. Die Daten lauten:

Alter in Jahren	9	6	12	10	8	9
Körpergröße in cm	130	125	145	140	130	140

$N = 6$

Sie ist daran interessiert, die Körpergröße anhand des Alters vorherzusagen.

a) (1 Punkt) Erstellen Sie anhand der Rohdaten ein Streudiagramm. Achten Sie auf

Alter in Jahren	9	6	12	10	8	9
Körpergröße in cm	130	125	145	140	130	140

$N = 6$

Sie ist daran interessiert, die Körpergröße anhand des Alters vorherzusagen.

a) (1 Punkt) Erstellen Sie anhand der Rohdaten ein Streudiagramm. Achten Sie auf die Wahl der richtigen Achsen für die Regression.

Anforderung für die ganze Aufgabe 2: matplotlib, numpy, scipy

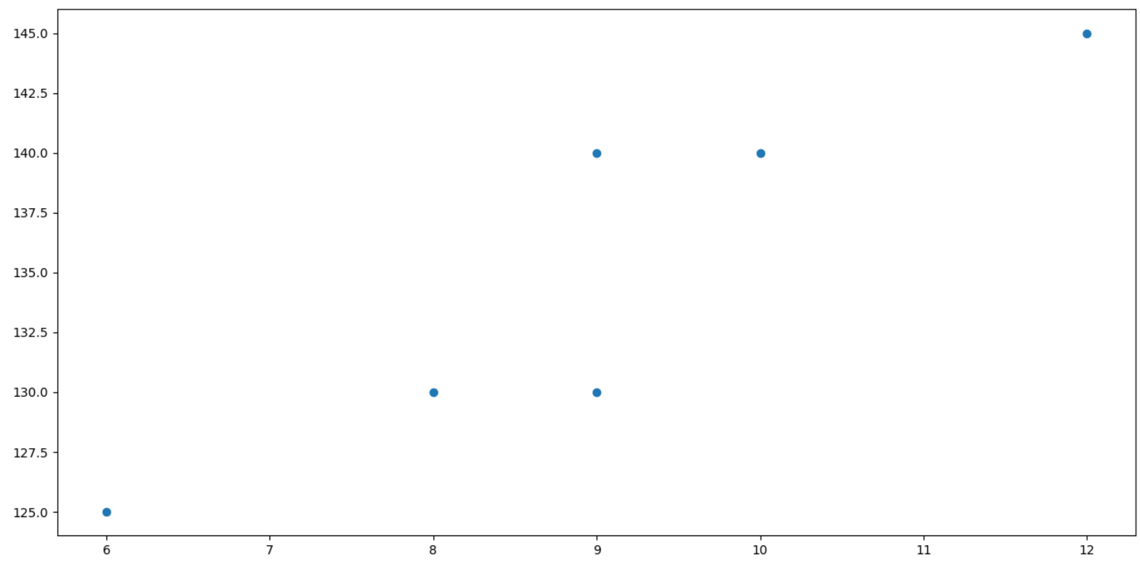

b) (1 Punkt) Berechnen Sie die Kovarianz zwischen Alter und Körpergröße.

$$\bar{x} = \frac{1}{6}(9+6+12+10+8+9) = 9$$

$$\bar{y} = \frac{1}{6}(130+125+145+140+130+140) = 135$$

$$s_{xy} = \frac{1}{5}\sum_{i=1}^{6}(x_i - \bar{x})(y_i - \bar{y}) = 14$$

c) (2 Punkte) Berechnen Sie den Korrelationskoeffizienten nach Bravais-Pearson zwischen Alter und Körpergröße.

$$\mathrm{var}_x = \frac{1}{5}(0^2 + (-3)^2 + 3^2 + 1^2 + (-1)^2 + 0^2) = \frac{1}{5}(20) = 4 \rightarrow s_x = 2$$

$$\mathrm{Var}_y = \frac{1}{5}((-5)^2 + (-10)^2 + 10^2 + 5^2 + (-5)^2 + 5^2) = \frac{1}{5}(300) = 60 \rightarrow s_y = 7{,}74$$

$$\rightarrow r_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{14}{2 \cdot 7{,}74} = 0{,}904$$

d) (2 Punkte) Führen Sie eine lineare Regression durch, d.h. berechnen Sie d und c und geben Sie die vollständige Regressionsgleichung an. Zeichnen Sie die Regressionsgerade in Ihr Streudiagramm aus a) ein.

$$d = \frac{s_{xy}}{s_x^2} = \frac{s_{xy}}{var_x} = \frac{14}{4} = 3{,}5$$

$$c = \bar{y} - d\bar{x} = 135 - 3{,}5 \cdot 9 = 103{,}5$$

$$\Rightarrow \quad y = 3{,}5x + 103{,}5$$

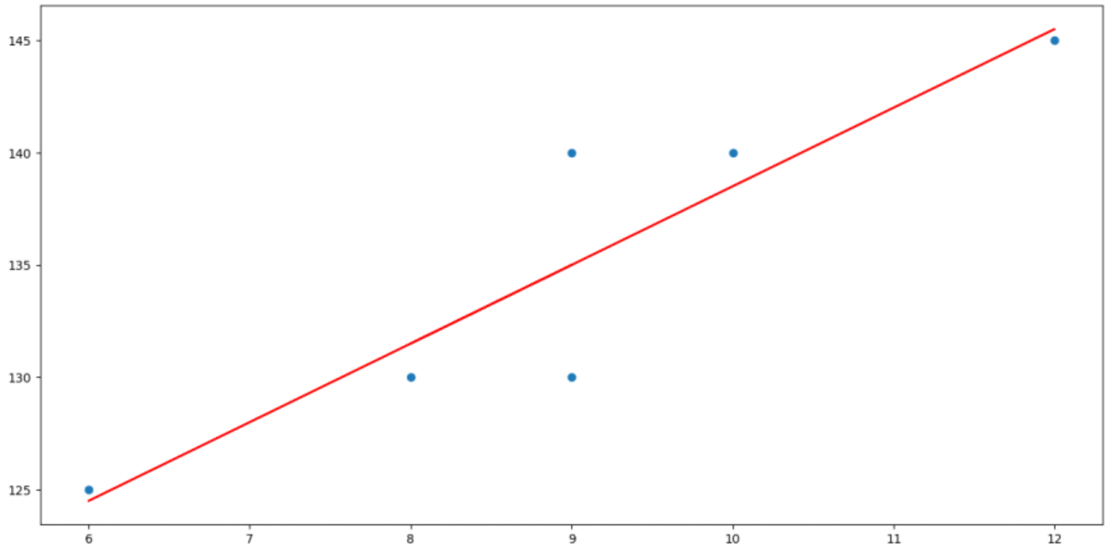

e) (2 Punkte) Bestimmen Sie den Rangkorrelationskoeffizienten nach Spearman für die Variablen Alter und Körpergröße. Vergeben Sie bei geteilten Rängen den jeweils mittleren Rang. Beispiel: (5, 4, 5, 6) hat die Ränge (2.5, 1, 2.5, 4).

Alter	9	6	12	10	8	9
Alter gerankt	**3.5**	**1**	**6**	**5**	**2**	**3.5**
Körpergröße	130	125	145	140	130	140
Körpergröße gerankt	**2.5**	**1**	**6**	**4.5**	**2.5**	**4.5**

$$r_{xy}^{Sp.} = 1 - \frac{6}{N(N^2-1)} \cdot \sum_{i=1}^{N} \left(R(x_i) - R(y_i)\right)^2$$

$$= 1 - \frac{6}{6(6^2-1)} \left(1^2 + 0^2 + 0^2 + 0{,}5^2 + (-0{,}5)^2 + (-1)^2\right)$$

$$= 1 - \frac{1}{35}(2{,}5) = 0{,}928$$